



دانشکده فنی دانشگاه تهران
دانشکده برق و کامپیوتر

تمرین ۵ سیستم‌های هوشمند

رایانامه
sharifi.sina1377@gmail.com
hesam.77s@gmail.com

طراحان:
سینا شریفی
امیرحسام سلیم نیا

نیم سال اول ۱۳۹۹-۱۴۰۰

دانشجویان عزیز، قبل از پاسخ‌گوئی به سوالات به نکات زیر توجه کنید:

۱. کدها و گزارش باید با الگو **IS_HW5_StudentNumber.zip** در محل تعیین شده آپلود شوند.
۲. گزارش کار شما نیز از معیارهای ارزیابی خواهد بود، در نتیجه زمان کافی برای تکمیل آن اختصاص دهید.
۳. در صورتی که از **Jupyter Notebook** نیاز به ارسال جداگانه کدها و گزارش نیست و هردو را می‌توانید در یک فایل **Notebook** ارائه دهید. حتما خروجی **html** یا **pdf** فایل **Notebook** خود را نیز همراه فایل **Notebook** ارسال نمایید.
۴. شما می‌توانید سوالات خود را از طریق ایمیل **hesam.77s@gmail.com** و **sharifi.sina1377@gmail.com** بپرسید.

۱. به سوالات تشریحی زیر پاسخ دهید.

(آ) مفهوم پاداش لحظه‌ای و تاخیری را در یادگیری تقویتی توضیح دهید.

(ب) در چه مواردی ترجیح می‌دهیم از روش‌های مستقل از مدل بجای روش‌های مبتنی بر مدل استفاده کنیم؟ توضیح دهید.

(ج) سه مرحله از الگوریتم *policy iteration* را روی جدول زیر اجرا کنید.
فرض کنید در انتخاب جهت، به علت وجود نامعینی، به احتمال 0.6 به سمت جهت دلخواه و 0.2 به دو جهت مجاور می‌رویم. علاوه بر این مقدار $\alpha = 0, 2$ و برای حرکت، جایزه‌ی منفی در نظر نمی‌گیریم.

			3
			-2

شکل ۱: جدول سوال یک

۲. هدف از این سوال پیاده سازی الگوریتم $Q - Learning$ می باشد.

در این سوال، یک عامل داریم که در یک فضای $n * n$ قرار گرفته، این عامل از یک نقطه مشخص شروع کرده و هدف این است که به نقطه مقصد برسد. این عامل میتواند ۴ جهت (U, D, L, R) را انتخاب کند ولی با انتخاب هر جهت، ممکن است به احتمال $P = 0,05$ به مقصد دلخواه نرسد و به طور تصادفی به یکی از ۳ خانه دیگر برود. غیر از خانه نهایی که دارای جایزه $R1 = 100$ است، تعدادی خانه دیگر نیز در فضا وجود دارد که عبور از آن ها دارای جایزه $R2$ میباشد. تعدادی از خانه ها نیز دارای هزینه ی $c1 = -0.01$ و $c2 = -20$ و $c3 = -100$ میباشد. نقشه ی فضای که عامل در آن قرار دارد در فایلی به نام $ENV.map$ قرار داده شده است که خانه‌ها با توجه به جدول زیر مقدار دهی شده‌اند. ($n = 15$, $\gamma = 0.9$)

0	state with cost c1
1	starting point
2	state with cost c2
3	state with cost R1
4	state with cost R2
5	state with cost R3

شکل ۲: جدول سوال دو

پس از حداقل ۳۰۰۰ دور یادگیری با روش‌های $Q - Learning$ و سیاست تصمیم‌گیری $Softmax$ با ثابت $\beta = 1$ یک بار به ازای $R2 = 0$ و بار دیگر به ازای $R2 = 30$ موارد زیر را بدست آورده و گزارش کنید:

(آ) نمودار مجموع پاداش دریافتی در طول مسیر را بر حسب $epoch$ محاسبه کرده و رسم نمایید.

(ب) سیاست بهینه در شرایط حریصانه (مسیر بهینه) را برای هر دو مقدار $R2 = 0$ و $R2 = 30$ محاسبه کنید.

(ج) مزیت و تفاوت سیاست $Softmax$ در مقایسه با روش $\epsilon - greedy$ بیان کنید.

موفق باشید